

Министерство науки и высшего образования Российской Федерации  
Санкт-Петербургский политехнический университет Петра Великого  
Институт физики, нанотехнологий и телекоммуникаций

Работа допущена к защите

Директор высшей школы

прикладной физики и космических  
технологий

\_\_\_\_\_ / Е.Н. Величко

«\_\_\_» \_\_\_\_\_ 2021 г.

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА**  
**РАБОТА БАКАЛАВРА**  
**ИЗВЛЕЧЕНИЕ ДИАГНОСТИЧЕСКОЙ ИНФОРМАЦИИ ИЗ**  
**ИЗОБРАЖЕНИЙ ЭКГ С ПОМОЩЬЮ МЕТОДОВ ГЛУБОКОГО**  
**ОБУЧЕНИЯ**

по направлению подготовки 11.03.02 – «Инфокоммуникационные технологии и  
системы связи»

профиль 11.03.02\_01 – «Системы мобильной связи»

Выполнил

студент гр. 3431102/70101

Г.М. Костин

Научные руководители

ассистент ВШПФиКТ, к.т.н.

доцент ВШПФиКТ, к.т.н.

В.А. Павлов

А.М. Уланов

Консультант

по нормоконтролю

З.А. Забалуева

Санкт-Петербург

2021



## РЕФЕРАТ

На 41 с., 23 рисунка, 7 таблиц

**КЛЮЧЕВЫЕ СЛОВА:** КОМПЬЮТЕРНОЕ ЗРЕНИЕ, ЭЛЕКТРОКАРДИОГРАММА, СВЁРТОЧНЫЕ НЕЙРОННЫЕ СЕТИ, СЕГМЕНТАЦИЯ, ГЛУБОКОЕ ОБУЧЕНИЕ, U-NET, YOLACT, ИЗВЛЕЧЕНИЕ ИНФОРМАЦИИ

Тема выпускной квалификационной работы: «Извлечение диагностической информации из изображений ЭКГ с помощью глубокого обучения».

Данная работа посвящена реализации алгоритма извлечения диагностической информации из изображений ЭКГ с помощью методов глубокого обучения. Были рассмотрены и проанализированы методы на основе глубокого обучения и алгоритмы классической сегментации. Анализ показал об неэффективности использования классических методов для решения поставленной задачи из-за имеющихся недостатков, таких как невозможность обеспечения связной сегментированной зоны ЭКГ-сигнала, необходимость непосредственного участия пользователя в случаях выделения объекта ограничивающим прямоугольником, ввода количества кластеров и других аспектов. Нейросетевая архитектура U-Net была выбрана для нахождения и ограничивания области ЭКГ-сигнала на изображении ЭКГ, обучение которой производилось на разработанном наборе данных.

В среде разработки MATLAB был реализован алгоритм по автоматическому сегментированию и оцифровке ЭКГ-сигнала. Были получены оценки коэффициента Dice для оценивания достоверности работы нейросетевой архитектуры, значения которых свидетельствуют о высокой точности предложенного метода решения поставленной задачи.

## ABSTRACT

41 pages, 23 pictures, 7 tables

KEYWORDS: COMPUTER VISION, ELECTROCARDIOGRAM, CONVOLUTIONAL NEURAL NETWORKS, SEGMENTATION, DEEP LEARNING, U-NET, YOLACT, EXTRACTING INFORMATION

The subject of the graduate qualification work is “Extract diagnostic information from ECG images using deep learning”.

This work is devoted to the implementation of the algorithm for extracting diagnostic information from the ECG using deep learning methods. Methods based on deep learning and classical segmentation algorithms were considered and analyzed. The analysis showed the inefficiency of using classical methods to solve the problem due to the existing shortcomings, such as the inability to provide a coherent segmented zone of the ECG signal, the need for direct user participation in cases of object allocation by bounding rectangles, entering the number of clusters, and other aspects. The U-Net neural network architecture was chosen to find and limit the ECG signal region in the ECG image, which was trained on the developed data set.

In the development environment of the MATLAB package, an algorithm for automatic segmentation and digitization of the ECG signal was implemented. Estimates of the bone coefficient were obtained for evaluating the reliability of the neural network architecture, the values of which indicate the high accuracy of the proposed method for solving the problem.

## СОДЕРЖАНИЕ

Введение.....	5
Глава 1. Анализ существующих алгоритмов сегментации объектов на изображении .....	7
1.1. Сегментация выделением краев .....	7
1.2. Пороговый метод .....	10
1.3. Сегментация по морфологическим водоразделам.....	12
1.4. Сегментация методом $K$ -средних .....	13
1.5. Комбинационный метод.....	14
1.6. Выводы.....	16
Глава 2. Нейросетевые подходы к решению задач сегментации объектов на изображениях.....	18
2.1. U-Net.....	18
2.2. YOLACT.....	23
2.3. Выводы.....	25
Глава 3. Реализация алгоритма извлечения диагностической информации из изображений ЭКГ .....	27
3.1. Разработка алгоритма .....	27
3.2. Выводы.....	37
Заключение .....	38
Список литературы .....	40

## ВВЕДЕНИЕ

Электрокардиография (ЭКГ) является распространенным инструментальным методом диагностики сердечно-сосудистых заболеваний, к числу которых относятся как нарушение сердечного ритма и проводимости, с момента его введение в 1902 году. Суть метода предельно проста: запись разности потенциалов с поверхности тела пациента. Электрическую активность сердца отражают изменения разности потенциалов на протяжении времени проводимой диагностики. Это процессы распространения волны сокращения по сердцу, поляризации и деполяризации водителей ритма и проводящих путей.

На сегодняшний день существует обширный класс устройств, которые позволяют получать электрокардиограмму, но большинство паттернов сердечных заболеваний основаны на устаревших наборах данных и пошаговых алгоритмах интерпретации результатов ЭКГ. Из этого можно сделать вывод, что субъективная оценка оператора, в нашем случае медицинского работника, является основным недостатком, поскольку из-за недостаточного опыта и сопутствующих обстоятельств, таких как отвлекающие события и усталость, возрастает вероятность возникновения ошибки в постановке диагноза, которая, порой, может привести к трагическим последствиям для исследуемого пациента.

Переход ЭКГ-графиков от бумажной формы к электронным ЭКГ-сигналам позволяет использовать дополнительное программное обеспечение для автоматического анализа ЭКГ [19] с последующим выявлением признаков, на которые следует обратить внимание оператору. На текущий момент оцифрованные ЭКГ-сигналы позволяют объективно оценить такие параметры, как PR, QRS, QT интервалы, дисперсия и высота ST, а также ранее упущенные из виду показания, как морфология Т-волны или пространственный угол QRS-T. В пример такой системы можно привести прикроватные мониторы, которые автоматически сигнализируют о нарушениях работы сердца.

По статистике, которая была приведена Всемирной организацией здравоохранения, первое место по всем смертям занимают заболевания, связанные с сердцем и кровеносными сосудами. Так, в 2016 году, от ССЗ умерло 17,9 миллионов человек, 85% смертей которых приходится на инсульты и сердечные приступы [11]. Также интересным фактом является то, что страны со средним и низким уровнем дохода больше остальных подвержены к сердечно-сосудистым заболеваниям (ССЗ). Большинство бюджетных медицинских учреждений не имеет возможности моментально обновить имеющиеся устройства для получения электрокардиограмм, что приводит к невозможному использованию вышеупомянутых дополнительных программных обеспечений для автоматического анализа ЭКГ.

Стоит отметить, что достижения в области машинного обучения оказали значительное влияние в областях, которые связаны с сигналами [9]. Можно с уверенностью сказать, что сбор больших данных из наборов ЭКГ-сигналов делает их подходящими для подходов машинного обучения. Таким образом, первым этапом является достоверное извлечение диагностической информации из изображений ЭКГ с дальнейшим воспроизведением оцифрованной формы ЭКГ-сигнала.

Целью работы является реализация и применение алгоритма извлечения диагностической информации из изображений ЭКГ на основе свёрточных нейронных сетей для обеспечения надежной и воспроизводимой оцифрованной формы ЭКГ-сигнала.

Задачами, необходимыми для достижения поставленной цели, являются:

1. Обзор и анализ существующих алгоритмов сегментации.
2. Выбор алгоритма, удовлетворяющего поставленным в цели условиям.
3. Обучение выбранного алгоритма на разработанном наборе данных и оценка полученных результатов.
4. Реализация алгоритма извлечения диагностической информации из изображений ЭКГ.
5. Получение экспериментальных результатов.

## ГЛАВА 1. АНАЛИЗ СУЩЕСТВУЮЩИХ АЛГОРИТМОВ СЕГМЕНТАЦИИ ОБЪЕКТОВ НА ИЗОБРАЖЕНИИ

Получение числовых значений сигнала из изображения – одна из основных задач при классификации ЭКГ сигналов. Один из способов выполнения поставленной задачи – использование алгоритмов сегментации, которые выполняют функции классификации и разделения пикселей по заданным критериям.

Алгоритмы сегментации имеют широкий спектр применений в различных областях науки и техники. К примеру, их используют в медицинских целях для обнаружения различных заболеваний по снимкам компьютерной томографии при помощи определения форм и контуров рассматриваемых объектов. В частности, таким образом можно обнаружить пневмонию или рак легких [7].

Методы сегментации, в зависимости от требований к скорости или точности работы, можно разделить на две основные категории. Первая – классические методы, которые не требуют больших затрат ресурсов оборудования. Вторая – методы, которые основываются на использовании свёрточных нейронных сетей, другими словами, на основе глубокого обучения.

Рассмотрим классические алгоритмы сегментации объектов на изображении. Стоит отметить, что исходное изображение переводится из цветовой модели RGB в Grayscale для дальнейшего сравнения алгоритмов сегментации объектов. Для этого необходимо воспользоваться формулой для HDTV [2]:

$$X = 0,2126 \cdot R + 0,7152 \cdot G + 0,0722 \cdot B,$$

где  $R$  – красный,  $G$  – зеленый и  $B$  – синий каналы изображения в цветовой модели RGB соответственно.

### 1.1. Сегментация выделением краев

Наиболее часто применяемым алгоритмом сегментации изображений является метод сегментации краев. На границах исследуемых областей исходного одноканального изображения могут появляться резкие яркостные локальные изменения, на которых и базируется данный метод.



В цифровых изображениях встречаются три вида яркостных локальных изменений: перепады, линии и изолированные точки. Если в элементе изображения происходит резкое изменение функции яркости, то такой элемент называется пикселем перепада, где перепад – это совокупность набора элементов. Линия в свою очередь является участком разрыва, у которой значения яркости элементов больше, чем значение яркости по обе стороны от нее. А изолированная точка – это массив, ширина и длина которого составляет 1 элемент или, другими словами, одиночный пиксель. Сегментация выделением краев выполняется методами локальной обработки изображений, которые выявляют пиксели перепада. Если значение интенсивности пикселей изображения по обе стороны от линии на порядок выше, либо на порядок ниже, чем значение интенсивности самой линии, то такая линия является участком перепада.

Имеется множество алгоритмов выделения краев для сегментации изображения [18], к которым относятся операторы Собеля, Превитта, Робертса, Кэнни и другие. К примеру, оператор Кэнни является одним из мощнейших методов выделения краев для сегментации изображения [10], который можно описать следующим образом:

- 1) Входное изображение подвергается сглаживанию посредством фильтра Гаусса, у которого фиксированное стандартное отклонение  $\sigma$ , для минимизации шума.
- 2) Задаются параметры  $G_x$  и  $G_y$  для вычисления направления края и градиента по формулам (1.2) и (1.3) соответственно. Стоит отметить, что заданные параметры должны удовлетворять поиску на размытом изображении диагональных, горизонтальных и вертикальных краев. Угол направления края обязательно округляется и принимает одно из следующих значений:  $0^\circ$ ,  $45^\circ$ ,  $90^\circ$  или  $135^\circ$ .
- 3) Точки перепада, которые являются точками локального максимума градиента, оказывают влияние на рост гребней изображения. Всем точкам, которые не находятся на выбранном гребне, присваиваются нулевые значения, в результате чего образуется тонкая линия.

- 4) Пиксели гребня подвергаются пороговой обработке  $T_1$  и  $T_2$  (где  $T_1$  меньше, чем  $T_2$ ). Пиксели называются «слабыми», если величина пикселей гребня меньше, чем  $T_1$ . Пиксели называются «сильными», если величина пикселей гребня больше, чем  $T_2$ .
- 5) Алгоритм совершает соединение, добавляя к сильным пикселям слабые, которые в свою очередь 8-связаны с сильными.

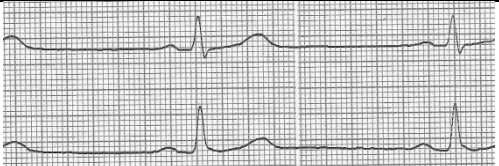
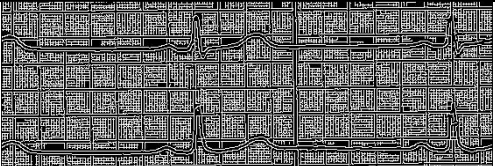






$$\alpha(x, y) = \arctg \left( \frac{G_y}{G_x} \right) \quad (1.2)$$

$$g(x, y) = \sqrt{G_x^2 + G_y^2} \quad (1.3)$$

В табл. 1.1 приведены результаты сегментирования выделением краев оператором Кэнни. Как можно заметить, возможны возникновения разрыва краев и выделения краев фона, что делает невозможным использование данных алгоритмов для поставленных задач, поскольку не позволяет обеспечить точную сегментацию исследуемого объекта.

Таблица 1.1

Результаты работы алгоритма сегментации выделением краев оператором  
Кэнни

№	$[T_1 T_2]$	$\sigma$	Исходное изображение	Результат сегментации выделением краев
1	—	—		
2	—	2		
3	[0.2 0.6]	—		
4	[0.2 0.6]	2		

## 1.2. Пороговый метод

Центральную позицию в проблемно ориентированных задачах сегментации цифровых изображений занимают пороговые преобразования. Суть данного алгоритма заключается в разделении элементов  $f(x, y)$  исследуемого изображения в цветовой модели Grayscale на полигоны по заданным критериям яркости. Элементы  $f(x, y)$  находятся в интервале от «0», что является черным цветом, до «255», что является белым цветом. Результатом работы метода будет являться бинарное изображение [5], значения элементов  $g(x, y)$  которого в свою очередь будут классифицированы и разделены на полигоны в соответствии с выбранным порогом  $T$  по критерию яркости и может иметь одно из двух возможных значений яркости для каждого сформированного полигона:

$$g(x, y) = \begin{cases} 1, & \text{если } f(x, y) \geq T \\ 0, & \text{если } f(x, y) < T \end{cases}$$

От оптимально выбранного порога  $T$ , значение которого влияет на требуемую точность, будет зависеть качество сегментации. Также не стоит забыть о том, что значение  $T$  напрямую зависит от исследуемых объектов на исследуемом изображении. Исходя из всего этого были разработаны методы пороговой сегментации [22], такие как: методы на основе формы гистограммы, метод Оцу и многие другие, которые позволяют вычислить оптимальный порог  $T$ .

Рассмотрим классический метод с глобальным порогом, где вычисление порога будет осуществляться визуально и с помощью метода Оцу. В первом случае необходимо визуально оценить гистограмму исходного изображения и выбрать оптимальный порог  $T$ , исходя из нашей субъективной оценки. Исходное изображение и его гистограмма представлены на рис. 1.1. Как видно, преобладающая часть пикселей имеют значения, лежащие в области от «225» до «255», что соответствует белому цвету.

Так как необходимо сегментировать только ЭКГ-сигнал, то можем задать порог  $T$  равным «20», «40», «60» и «80» соответственно. Результат представлен в табл. 1.2. Как можно заметить, отчетливей всего ЭКГ-сигнал виден при пороге  $T = 80$ , но также линия имеет разрывы, на фоне присутствуют артефакты, что не

дает возможности предоставить качественную сегментацию интересующего объекта и делает невозможным применение данного метода для поставленных задач.




Рис. 1.1. Исходное изображение (левый рисунок) и его гистограмма (правый рисунок)

Таблица 1.2

Результаты работы алгоритма сегментации пороговым методом

№	$T$	Исходное изображение	Результат сегментации пороговым методом
1	20		
2	40		
3	60		
4	70		

Теперь рассмотрим результат порогового метода, где выбор порога  $T$  осуществляется при помощи метода Оцу. Для этого необходимо воспользоваться встроенной функцией библиотеки Image Processing Toolbox [17].

Как видно из рис. 1.2, автоматически выбранный порог  $T$  не удовлетворяет стандартам сегментации ЭКГ-сигнала, за счет присутствия разметки в виде

миллиметровки, что делает невозможным использование данного метода для поставленных задач.

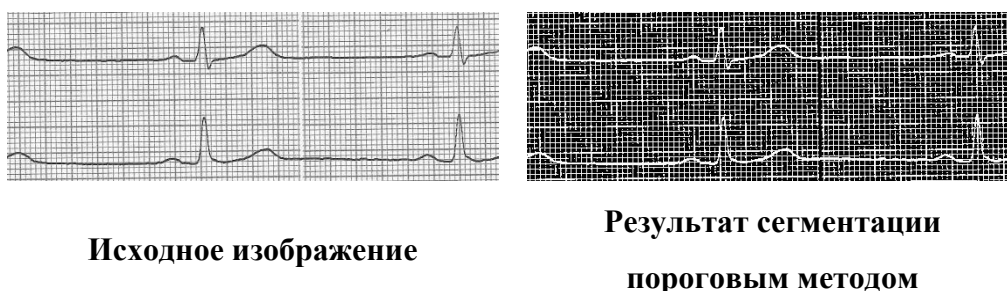


Рис. 1.2. Исходное изображение и результат сегментации пороговым методом

### 1.3. Сегментация по морфологическим водоразделам

Сегментация по морфологическим водоразделам [14] основана на отображении исследуемого изображения в цветовой модели Grayscale в виде трехмерной карты поверхности, где оси  $X$  и  $Y$  являются пространственными координатами, а ось  $Z$  соответствует уровню яркости, которая соответствует высоте поверхности. Суть данного метода заключается в том, чтобы «наполнить водой» низменности, участки поверхности с наименьшим значением яркости, для определения линии «примыкание вод окрестных бассейнов» и обнаружении границ интересующих объектов на исследуемом изображении в цветовой модели Grayscale до момента постановки последнего водораздела на участке поверхности с наибольшим значением яркости.

Сегментация по морфологическим водоразделам делится на две группы: базовые и маркерные. Базовый метод сегментации по морфологическим водоразделам в результате работы обеспечивает непрерывность границ объекта, но существенным недостатком является излишняя сегментация, которая возникает в результате наличия локальных неравномерностей яркости и шумов на изображении. Маркерный метод сегментации по морфологическим водоразделам лишен недостатков базового подхода, так как позволяет обеспечивать контроль от излишней сегментации за счёт ручной установки допустимого количества полигонов по периметру центра необходимого маркера.

В связи с отсутствием однородного фона исследуемых изображений ЭКГ, а также необходимости присутствия пользователя для совершения ручной регулировки параметров, данный метод не дает возможности достичь точной сегментации ЭКГ-сигнала и делает нецелесообразным его использование для поставленных задач.

#### 1.4. Сегментация методом $K$ -средних

Особенно распространённым методом кластерного анализа является сегментация методом  $K$ -средних [13], смысл которого заключается в разбиение комплекта данных, которые заранее неизвестны, на фиксированное количество кластеров, характеристики которых схожи. Присваивание  $K$ -го количества кластеров каждому пикселю первичных данных по условию наименьшего квадрата евклидовой нормы [4]. Эмпирическим путем происходит достижение приемлемого количества кластеров, значение которых требуется задать для работоспособности данного алгоритма.

Предположим, что имеется элементы набора данных  $x_i, i = 1, 2, \dots, n$ , где  $n \in N$ , которые необходимо разделить на  $K$  кластеров  $y_j, j = 1, 2, \dots, k$ , где  $k \in N$ , тогда алгоритм работы метода будет выглядеть следующим образом:

- 1) Предположим, что значение кластеров изначально известно, тогда произведем инициализацию кластеров произвольным образом по  $x_i$ .
- 2) Для того, чтобы сопоставить соседний кластер каждому элементу  $x_i$  необходимо рассчитать наименьший квадрат евклидовой нормы:

$$\arg \min_c \sum_{i=1}^k \sum_{x \in C_i} d(x, y_j) = \arg \min_c \sum_{i=1}^k \sum_{x \in C_i} \|x - y_j\|^2,$$

где  $C_i$  является набором элементов  $x_i$ , которые принадлежат  $i$ -му кластеру:

$$C_i = \{j : d(x_j, y_i) \leq (x_j, y_o), \text{ где } o \neq i, o = 1, 2, \dots, n\}.$$

- 3) Устанавливается положение всех кластеров, которое равно среднему значению всех элементов данных, которые принадлежат данному кластеру при  $\forall i$ :

$$y_i = \frac{1}{|C_i|} \sum_{j \in C_i} x_j,$$

где  $|C_i|$  – количество элементов  $C_i$ .

- 4) Цикл будет продолжаться до тех пор, пока позиция всех кластеров не перестанет изменяться.

В связи с тем, что инициализация кластеров производится произвольным образом, а также существует необходимость задавать вручную их количество, то результаты применения данного алгоритма будут изменяться при последующих запусках. Вышеперечисленные недостатки не дают возможности добиться точной и стабильной сегментации ЭКГ-сигналов и делает невозможным его использование для поставленных задач.

### 1.5. Комбинационный метод

Сегментация комбинационным методом заключается в использовании адаптированного порогового метода для трехканальных изображений и применении морфологической обработки.

В первую очередь следует перевести входное/исходное изображение из цветовой модели RGB в HSV для дальнейшей работы. Исходное изображение представлено на рис. 1.3. К достоинствам цветовой модели HSV можно отнести более привычное отображение информации о цвете, а именно:  $H$ -канал – отвечает за цветовой тон;  $S$ -канал – отвечает за насыщенность;  $V$ -канал – отвечает за яркость. Трехмерную визуализацию пространства HSV можно пронаблюдать на рис. 1.4. Так как сигнал ЭКГ на исходных изображениях имеет преимущественно черный цвет, то будет достаточно установить порог лишь на  $V$ -канале с диапазоном от 0 до 0.4. Также необходимо инвертировать полученный результат для дальнейшей комфортной работы. Для данных итераций воспользуемся функцией [16] «*imadjust*». Результат представлен на рис. 1.5.




Рис. 1.3. Исходное изображение




Рис.1.4. Трехмерная визуализация пространства HSV



Рис. 1.5. Результат работы функции «*imadjust*»

Как видно, полученные формы ЭКГ-сигналов хорошо сохранились, но для дальнейшей работы необходимо получить бинарную маску. Для этого воспользуемся функциями «*im2bw*» с порогом 0.2 и «*bwmorph*» с параметрами 'bridge', 'close' и 'skel' соответственно. Результат представлен на рис. 1.6.

Для избавления от одиночных пикселей, которые могут помешать дальнейшей работе, был написан алгоритм, который не затрагивает основную форму ЭКГ сигнала. Результат представлен на рис. 1.7.

Как видно, результат сегментации комбинационным методом показывает хороший результат: сохранена форма ЭКГ-сигнала, отсутствуют артефактов



фона. Но также линии имеют разрывы, что не позволяет обеспечить точную сегментацию и делает невозможным использование данного метода для поставленных задач.




Рис. 1.6. Результат работы функций «*im2bw*» и «*bwmorph*»




Рис. 1.7. Результат работы алгоритма по избавлению одиночных пикселей

## 1.6. Выводы

На основе приведенного анализа существующих методов сегментации было выяснено, что классические методы сегментации, к которым относятся методы сегментации выделением краев, по порогу,  $K$ -средних, по морфологическим водоразделам и комбинационный метод, не подходят из-за имеющихся недостатков, в числе которых невозможность обеспечения связной сегментированной зоны ЭКГ-сигнала, необходимость непосредственного участия пользователя в случаях выделения объекта ограничивающим прямоугольником, ввода количества кластеров и других аспектов.

Методы сегментации на основе глубокого обучения, базирующиеся на использовании свёрточных нейронных сетей, лишены многих недостатков классических методов.

Целью работы является реализация и применение алгоритма извлечения диагностической информации из изображений ЭКГ при помощи архитектур на основе свёрточных нейронных сетей.

Дальнейшими задачами, которые необходимы для достижения поставленной цели, являются:

1. Выбор и обучение алгоритма на разработанном наборе данных и оценка полученных результатов.
2. Реализация алгоритма извлечения диагностической информации из изображений ЭКГ.
3. Получение экспериментальных результатов.

## ГЛАВА 2. НЕЙРОСЕТЕВЫЕ ПОДХОДЫ К РЕШЕНИЮ ЗАДАЧ СЕГМЕНТАЦИИ ОБЪЕКТОВ НА ИЗОБРАЖЕНИЯХ

Глубокое обучение является объединением методов машинного обучения, которые основаны на обучении представлений, что упростило выполнения сегментации, показав при этом поразительные результаты.

Сегментацию нейросетевыми подходами можно разделить на 2 основные группы: семантическая и инстанс-сегментации. Семантическая сегментация обозначает присвоению каждому элементу фиксированную метку. Это является главным отличием от классификации, где всем элементам, принадлежащим изображению, присваивается лишь одна метка. Стоит отметить, что данный тип сегментации может определять множество объектов одного класса как единое целое. Инстанс-сегментация лишена недостатка семантической сегментации, поскольку объекты, принадлежащие одному классу, распознаются как независимые объекты, но в этом и заключается сложность данного типа по сравнению с предыдущим.

### 2.1. U-Net

U-Net [20] представляет собою улучшенную полносвёрточную нейронную сеть [16], состоящую из последовательных частей: энкодера и декодера, которые симметричны друг другу, что наблюдается на рис. 2.1. За счет этого сеть и получила свое название.

Каждым из четырех блоков, из которых состоит энкодер, с окном « $3 \times 3$ » выполняется две процедуры свёртки с дальнейшим использованием функции ReLU [12]. В конце с шагом 2 и окном « $2 \times 2$ » выполняется процедура уменьшения размерности карт признаков. Численность карт признаков удваивается после каждой из двух процедур. Каждым из четырех блоков, из которых состоит декодер, с окном « $3 \times 3$ » выполняется две процедуры свёртки с дальнейшим использованием функции ReLU вслед за реализацией процедуры развёртки. По сравнению с энкодером, в декодере происходит понижение вдвое численности карт

признаков после каждой из двух процедур. Стоит отметить, что между декодером и энкодером находятся два свёрточных слоя, размер окна которых является « $3 \times 3$ », с применением ReLU.




Рис. 2.1. Архитектура U-Net

Внимательно изучив структуру улучшенной полносвёрточной нейронной сети на рис. 2.1, можно сделать вывод, что архитектура U-Net применяет прием объединения карт признаков, которые находятся напротив друг друга. Перед тем, как произвести объединение карт признаков энкодера, необходимо осуществить обрезание и суммирование аналогичных по размерам карт признаков декодера. Восстановление в большей степени пространственной информации происходит за счет повышения числа слоев развёртки и объединением блоков. Свёрточный слой размером « $1 \times 1$ », количество каналов которого соответствует количеству классов, является заключительным слоем архитектуры U-Net.

Рассмотрим примеры, которые демонстрируют работу данного нейресетевого подхода. Во всех примерах будем использовать одноканальные изображения (цветовая модель Grayscale).


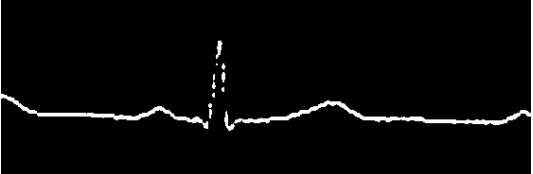
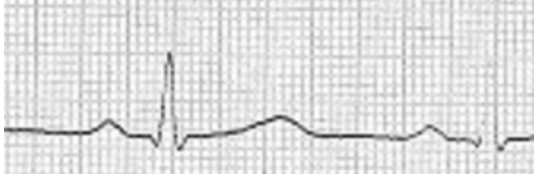
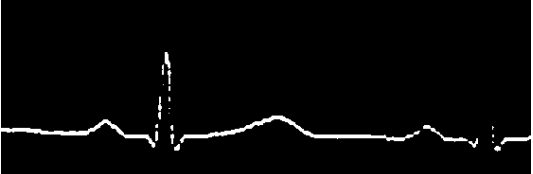
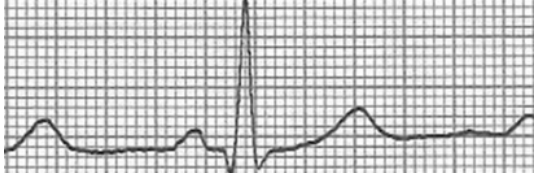
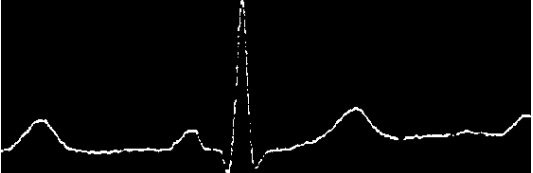
В первом случае для обучения полносверточной нейронной сети используются 90 изображений размером «192×560». Маски для обучения создаются при помощи комбинационного метода из классических алгоритмов сегментации объектов на изображениях. Исходные изображения и маски представлены в табл. 2.1. Как можно заметить, толщина линий на масках минимальна и имеются разрывы. Также присутствуют артефакты в виде одиночных пикселей. Результаты сегментирования ЭКГ-сигналов представлены на рис. 2.2.

Как видно, данный вариант обучения U-Net не позволяет добиться сегментирования ЭКГ сигналов, делает невозможным его использование для поставленных задач.

Рассмотрим второй случай, в котором используются 30 изображений размером «192×560». Исходные изображения и маски представлены в табл. 2.2. Как видно, толщина линий на масках стала больше по сравнению с предыдущим примером. Результаты сегментирования ЭКГ сигналов представлены на рис. 2.3.

Таблица 2.1

Исходные изображения и маски по исходным изображениям для обучения полносвёрточной нейронной сети U-Net

	Исходное изображение	Маска по исходному изображению
а)		
б)		
в)		

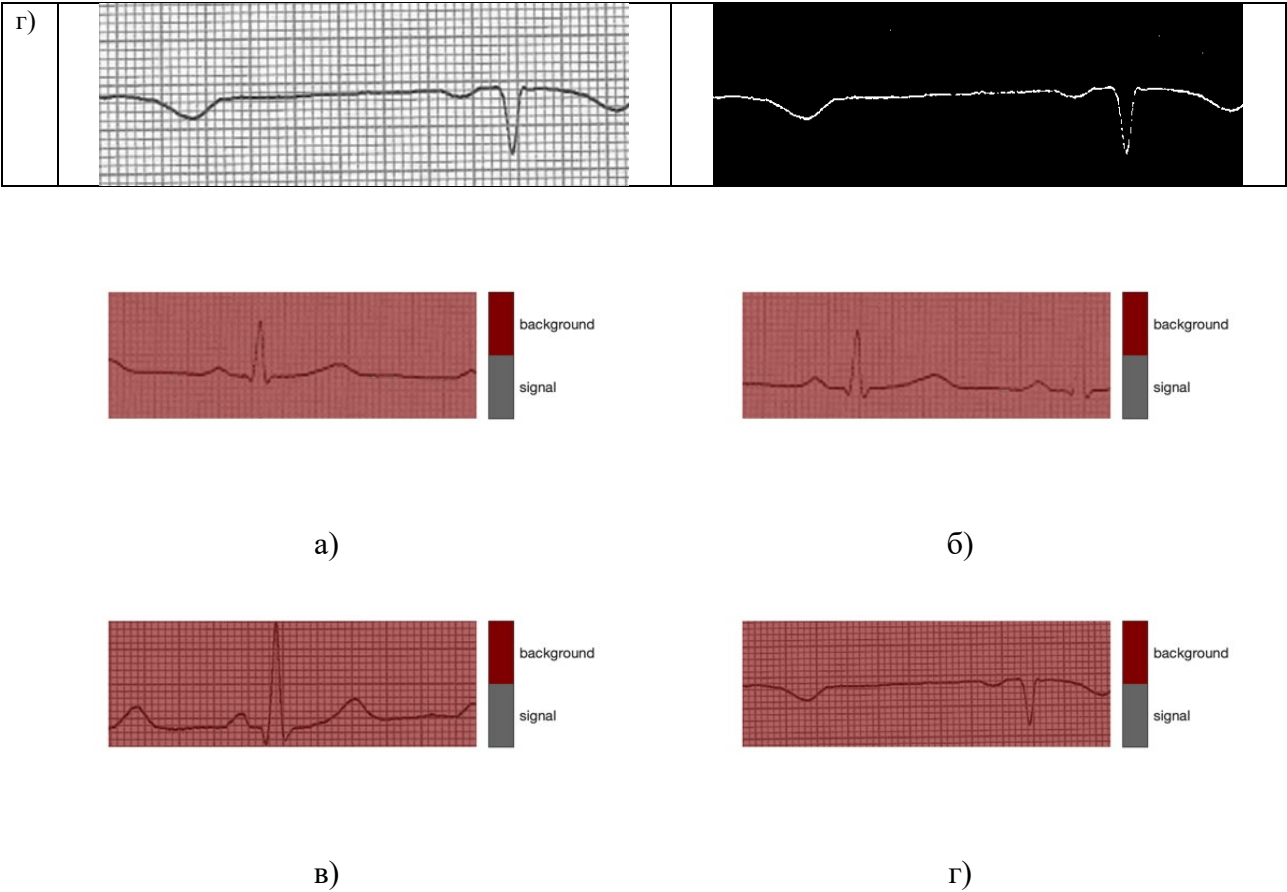
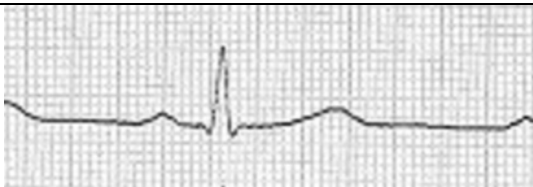

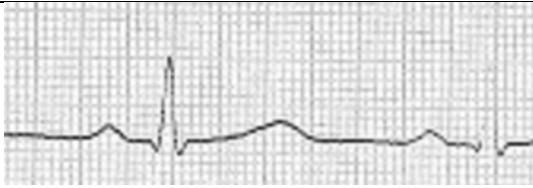
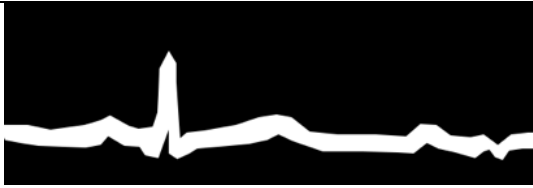
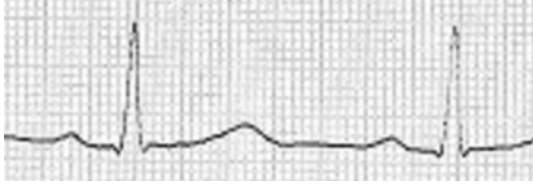
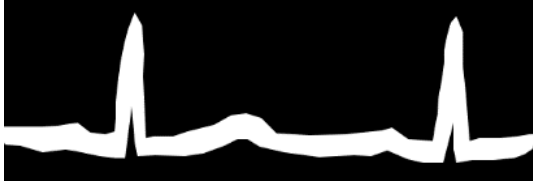


Рис. 2.2. Результаты сегментирования изображений ЭКГ при помощи U-Net

Таблица 2.2

Исходные изображения и маски по исходным изображениям для обучения полносвёрточной нейронной сети U-Net

	Исходное изображение	Маска по исходному изображению
а)		
б)		
в)		

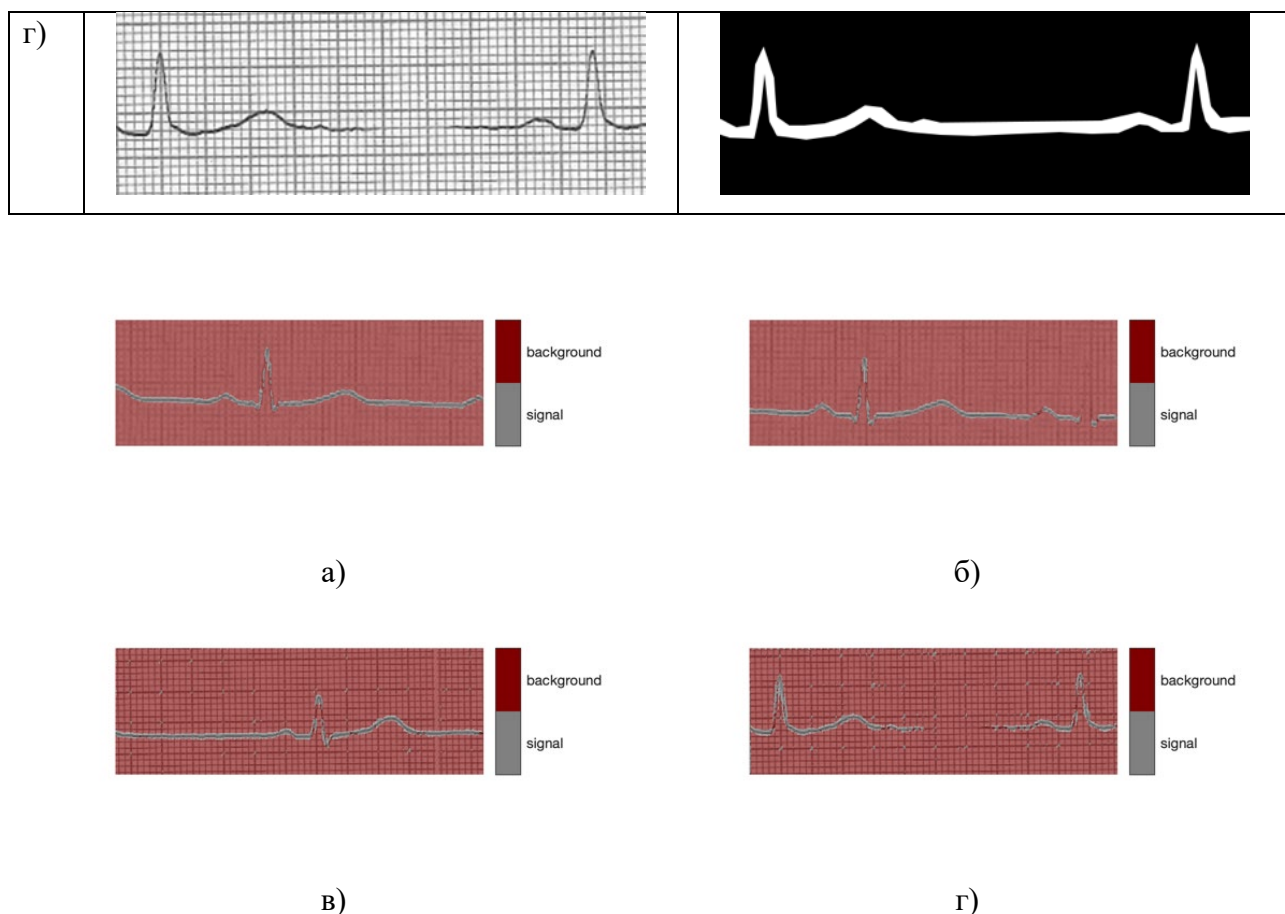


Рис. 2.3. Результаты сегментирования изображений ЭКГ при помощи U-Net

Как видно из результатов, представленных на рис. 2.3, данный вариант обучения U-Net сработал намного лучше: он смог локализовать ЭКГ сигналы на исходных изображениях. Стоит обратить внимание на исходное изображение (г) табл. 2.2: фон (миллиметровка) в данном случае на порядок ярче, чем в других приведенных примерах, что и дало артефакты сигнала на пересечениях линий миллиметровки (так как интенсивность цвета совпадает с сигналом) в результате сегментирования ЭКГ сигнала на рис. 2.3 (г).

U-Net обеспечивает сегментацию ЭКГ сигналов на высоком уровне, но не позволяет производить классификацию на 2 и более слоев в рамках одного класса.

## 2.2. YOLACT

YOLACT [8] является полностью свёрточной нейронной архитектурой, предназначение которой заключается в сегментации в режиме реального времени по образцам видеопоследовательностей и изображений. Особенностью данной нейронной сети заключается в том, что она создает набор коэффициентов и масок-прототипов для каждого отдельно взятого экземпляра, разделяя поставленную задачу сегментации на две параллельные области, которые представлены на рис. 2.4. За счет проведенных итераций YOLACT показывает высокие показатели скорости и точности сегментации.

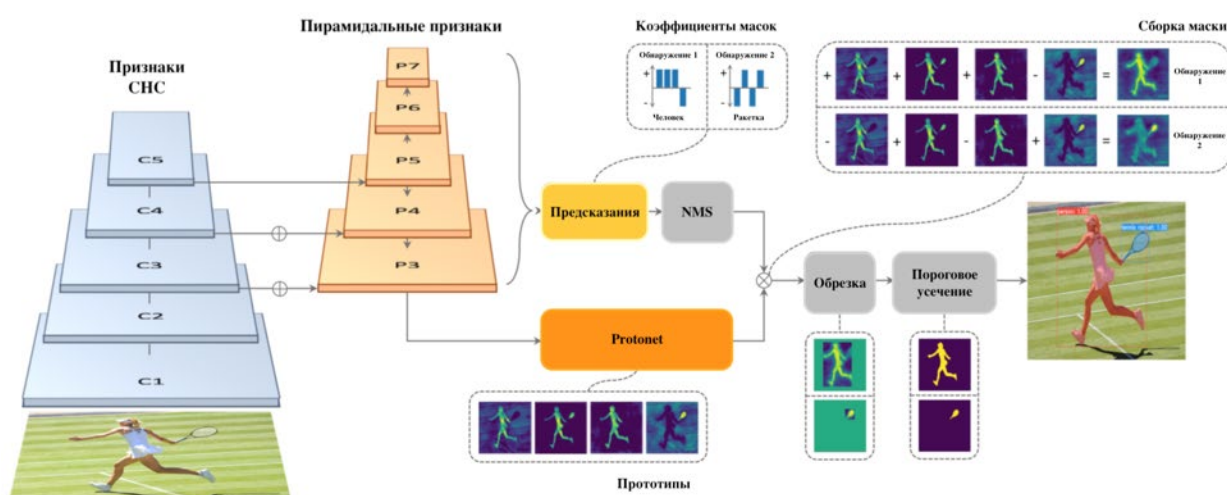


Рис. 2.4. Архитектура YOLACT

В ветки «Protonet», которая предназначена для локализации экземпляров, генерируются маски-прототипы с использованием полносвёрточной сети FCN [16], благодаря чему обеспечивается семантическая сегментированная маска с 25% разрешением от входного изображения на основе пирамидальных карт признаков. Количество масок-прототипов имеет значение «32», поскольку оно, по мнению авторов, обеспечивает необходимую точность при разумных затратах производительности. Параллельно слоям, предсказывающие координаты и прямоугольники, которые ограничивают область для каждого отдельного экзем-



пляра, предсказываются коэффициенты маски, использующиеся для определения их финальной сегментированной маски посредством произведения вычитания прототипов различных классов на моменте сборки.

Линейное соединение прототипов с соответствующими образцам коэффициентами называется сборкой, которая следует после результатов работы параллельных областей по созданию коэффициентов масок и самих масок-прототипов. После вышеперечисленных итераций происходит процесс обрезки по координатам прямоугольников для каждого отдельного экземпляра, которые были прогнозированы ранее. Данное действие позволяет отсеять области, вероятности которых ниже заданного пользователем порога.

Рассмотрим пример, который демонстрирует работу данного нейросетевого подхода.

В данном случае используются 30 изображений размером «512×1024». Маски для обучения создаются при помощи MS COCO [15] с фиксированным количеством ЭКГ-сигналов. Производилась разметка на исходном изображении областями с присвоением заранее известной метки класса. Пример изображений для обучения и созданные для них маски предоставлены на рис. 2.5. Обучение происходило на видеокарте NVIDIA GeForce GTX 1650 с 4 Гб видеопамяти. Результат работы архитектуры YOLACT, которая была обучена на разработанном наборе данных, представлен на рис. 2.6.

Как можно заметить, по сравнению с U-Net, YOLACT производит инстанс-сегментацию, что позволяет работать с каждым найденным ЭКГ-сигналом по отдельности и не требует дополнительных итераций для их разделения на отдельные слои. Но результат работы данного алгоритма несовершенен, поскольку присутствуют области интереса, которые не были классифицированы. Для исправления данной проблемы требуется увеличить количество изображений и масок и вновь запустить процесс обучения.

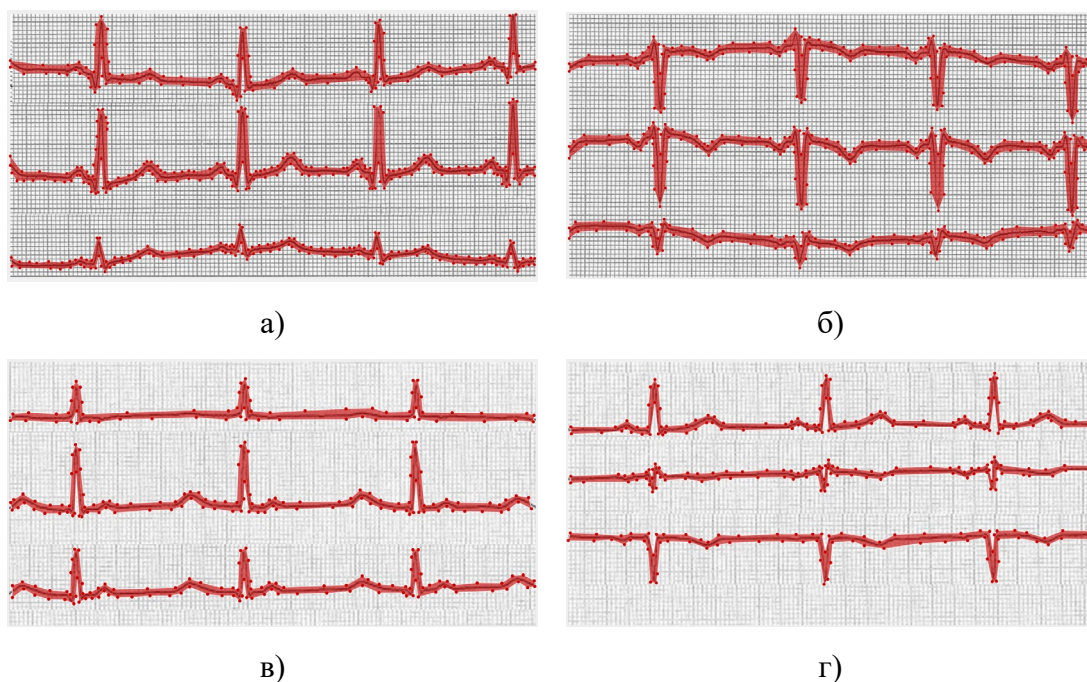


Рис. 2.5. Примеры исходных изображений и масок.




Рис. 2.6. Результат работы архитектуры YOLACT.

### 2.3. Выводы

Исходя из выше проведенного обзора нейросетевых структур, был сделан вывод о том, что наилучшим выбором для решения задачи извлечения диагностической информации из изображений ЭКГ является архитектура U-Net, которая удовлетворяет выдвинутым условиям, а именно получение приемлемых результатов сегментации при использовании ограниченного набора данных.

YOLOACT также показывает хорошие результаты, но требует на порядок больше обучающих изображений, а также времени для своего обучения.

## ГЛАВА 3. РЕАЛИЗАЦИЯ АЛГОРИТМА ИЗВЛЕЧЕНИЯ ДИАГНОСТИЧЕСКОЙ ИНФОРМАЦИИ ИЗ ИЗОБРАЖЕНИЙ ЭКГ

Внимание проведённой работы было сконцентрировано на реализации и применении алгоритма извлечения диагностической информации из изображений электрокардиограмм.

### 3.1. Разработка алгоритма

Первым этапом разработки алгоритма является использование нейросетевой архитектуры U-Net, описанной в главе 2, для получения сегментированных зон сигналов электрокардиограммы. Для ее обучения было использовано 100 изображений электрокардиограмм, находившихся в свободном доступе. Производилась разметка на исходном изображении областями с присвоением заранее известной метки класса «signal» или «background». Пример изображений для обучения и созданные для них маски предоставлены в табл. 3.1. Обучение происходило на видеокарте NVIDIA GeForce GTX 1650 с 4 Гб видеопамяти. Результаты работы архитектуры U-Net, обученной на разработанном наборе данных, представлены на рис. 3.1.

Как можно заметить, алгоритм хорошо справляется с поставленной задачей. Для проверки достоверности сегментации изображений ЭКГ воспользуемся коэффициентом Dice [3]:


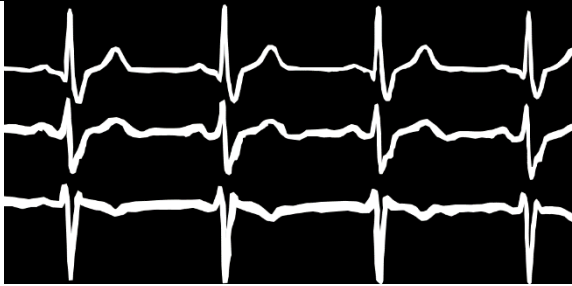

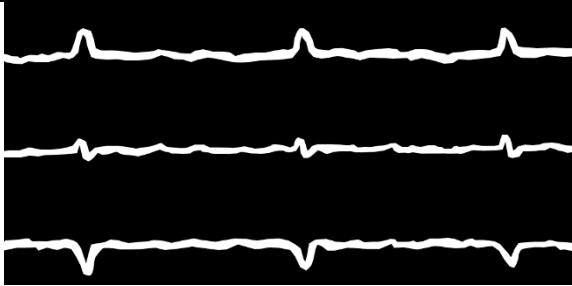

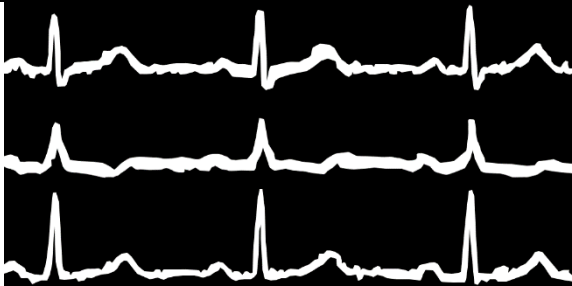
$$d(A, B) = \frac{2|A \cap B|}{|A| + |B|}, \quad (3.1)$$

где  $A$  – эталонная маска,  $B$  – маска, полученная в результате сегментации полносвёрточной нейронной сети U-Net. Так как в знаменателе находится сумма всех элементов двух рассматриваемых масок без вычитания их соединения, то необходимо домножить числитель на 2. Случай, когда маски пересекаются полностью означает то, что  $|A| = |B| = |A \cap B|$  и коэффициент Dice будет равен «1». В табл. 3.2. приведена выдержка результатов расчета коэффициента Dice для изображений из обучающей базы. Полученные результаты обосновываются тем, что

при сегментации образуются «битые пиксели» внутри маски, от которых необходимо избавиться при дальнейшей работе алгоритма.

Таблица 3.1

Исходные изображения и маски по исходным изображениям для обучения полносвёрточной нейронной сети U-Net

	Исходное изображение	Маска по исходному изображению
а)		
б)		
в)		



а)



б)

Рис. 3.1. Результаты сегментирования изображений ЭКГ при помощи U-Net

Таблица 3.2

## Результаты коэффициента Dice

№ изображения	1	10	20	30	40
d, %	88,08	87,77	87,87	87,81	87,64
№ изображения	50	60	70	80	90
d, %	90,23	90,26	89,90	89,60	89,60

Следующим этапом разрабатываемого алгоритма является нахождение и оцифровка линий миллиметровки, которые соответствуют 0,5 мВ по вертикали и 1 см по горизонтали на клетку соответственно для дальнейшего нормирования оцифрованного ЭКГ-сигнала.

Рассмотрим алгоритм, который представлен на рис. 3.2, на примере нахождения линий, соответствующих 1 см по на клетку по горизонтали.

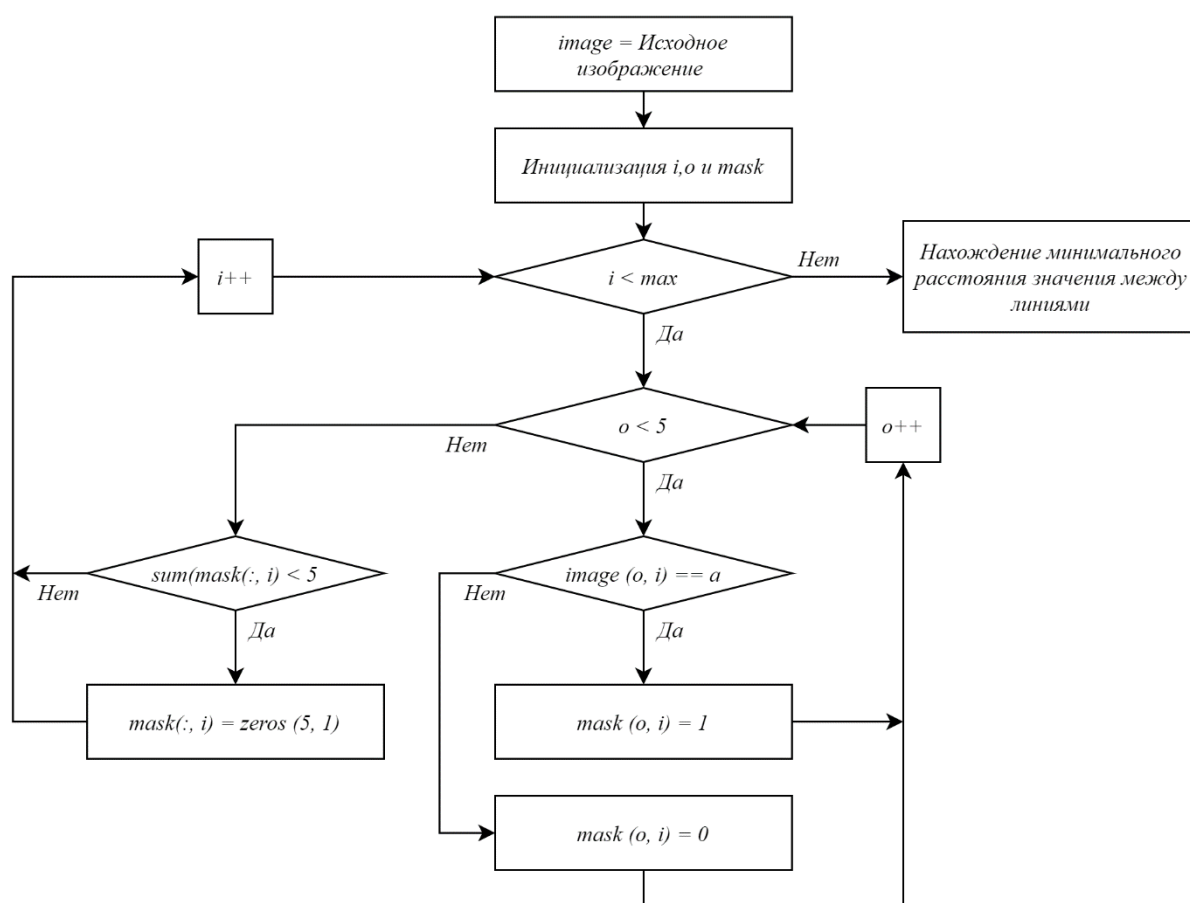


Рис. 3.2. Алгоритм оцифровки миллиметровки изображения ЭКГ

Так как данные линии имеют ограниченный диапазон цвета, воспользуемся принципом классического алгоритма сегментации, а именно – пороговым методом, для их нахождения. Изначально инициализируются необходимые переменные  $i$  и  $o$  для работы циклов, а также создаем переменную  $mask$  для записи последующей информации. Первый цикл отвечает за передвижение по горизонтали переменной  $image$ , где переменная  $max$  соответствует максимальному количеству столбцов переменной  $image$ . Второй цикл отвечает за передвижение по вертикали первых пяти строчек переменной  $image$ . Далее происходит проверка элемента  $(o, i)$  переменной  $image$  на соответствие значению переменной  $a$ , которая равняется значению цвета миллиметровки на изображении ЭКГ. При выполнении условия элемент  $(o, i)$  переменной  $mask$  принимает значение единицы, в обратном случае – нуля. После завершения второго цикла происходит проверка на количество «истин» в исследуемом столбце посредством суммирования всех элементов столбца. В случае, если сумма меньше «5», все элементы данного столбца принимают значение «0». После завершения первой части алгоритма производится расчет количества элементов между найденными столбцами и выбирается минимальное значение, которое и является значением длины клетки, соответствующей 1 см.

Последующий этап алгоритма является «улучшением» маски, а именно закрытие «пустых» областей внутри контура, полученной в ходе работы полносвёрточной нейронной сети U-Net. Для этого было принято решение воспользоваться классическими функциями морфологической обработки изображений, а именно «*imclose*», «*imerode*» и «*imdilate*». Результат представлен на рис. 3.3. При повторном расчете коэффициента Dice по формуле (3.1), результаты которых представлены в табл. 3.3, можно утверждать, что вышеперечисленные манипуляции повлияли благотворно.

Поскольку нейросетевой архитектура U-Net выполняет семантическую сегментацию объектов, а именно множество объектов одного класса определяются как одна единая маска, то необходимо выполнить разделение на слои.



Рис. 3.3. «Улучшенная» бинарная маска

Рассмотрев маски, полученные в ходе работы нейросетевой архитектуры U-Net, можно заметить, что они не пересекаются, а значит можно найти первый элемент каждого потенциального слоя для дальнейшего разделения. Алгоритм представлен на рис. 3.3.

Таблица 3.3

Результаты коэффициента Dice

№ изображения	1	10	20	30	40
d, %	91,70	91,84	92,08	90,50	89,97
№ изображения	50	60	70	80	90
d, %	93,01	92,16	91,25	90,10	93,50

Изначально инициализируются необходимые переменные  $n$  и  $a$ , а также  $maskYposition$ , в которую будут записываться значения строк, соответствующих первым элементам потенциальных слоев. Запускается цикл, который проверяет условие  $n < max$ , где  $max$  – количество строчек в переменной  $mask$ . Следующим шагом является проверка условия  $mask(n, 5) == 1$ , а именно является ли элемент  $(n, 5)$  матрицы  $mask$  равным «1», что означает принадлежность данного элемента к потенциальному слою. В случае выполнения условия, в элемент  $a$  переменной  $maskYposition$  записывается значение соответствующей строки и к переменным



$a$  и  $n$  прибавляются «1» и «25» соответственно. Значение «25» выбрано не случайно, поскольку оно гарантирует не попасть на ранее найденный потенциальный слой.

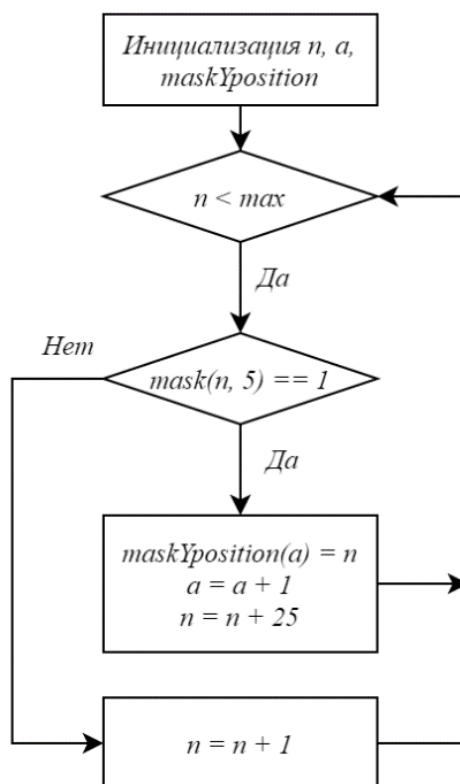


Рис. 3.3. Алгоритм нахождения первых элементов потенциальных слоев

Следующим действием является применение классического алгоритма сегментации по морфологическим водоразделам, описанного в первой главе, и разделение на слои. Алгоритм представлен на рис. 3.4.

Изначально следует инициализировать переменные  $i$ ,  $layers$ ,  $segN$ ,  $o$ ,  $p$  и  $maskW$ . Метод сегментации по морфологическим водоразделам позволяет разделить объекты на изображении посредством присваивания замкнутым контурам уникальных значений. Результат работы метода представлен на рис. 3.5 (а) и записывается в переменную  $maskW$ .

Следующим этапом является запуск цикла с условием  $i < \max$ , где  $\max$  – количество элементов переменной  $maskYposition$ . Далее в переменную  $segY$  записывается значение элемента  $(maskYposition(i), a)$  матрицы  $mask$  для дальнейшей идентификации слоя. Второй и третий циклы с условиями  $o < \maxX$  и  $p < \maxY$  соответственно, где  $\maxX$  и  $\maxY$  – количество столбцов и строк матрицы  $mask$ , необходимы для того, чтобы «пройтись» по всем столбцам и строкам матрицы  $mask$ . Условие  $maskW(p, o) == segN$  проверяет, соответствует ли элемент  $(p, o)$  матрицы  $maskW$  значению переменной  $segN$ . В случае выполнения условия в элемент  $(p, o, i)$  переменной  $maskN$  записывается «1», в противном случае – «0». На рис. 3.5 (б) представлен результат разделения сегментированной маски на слои.

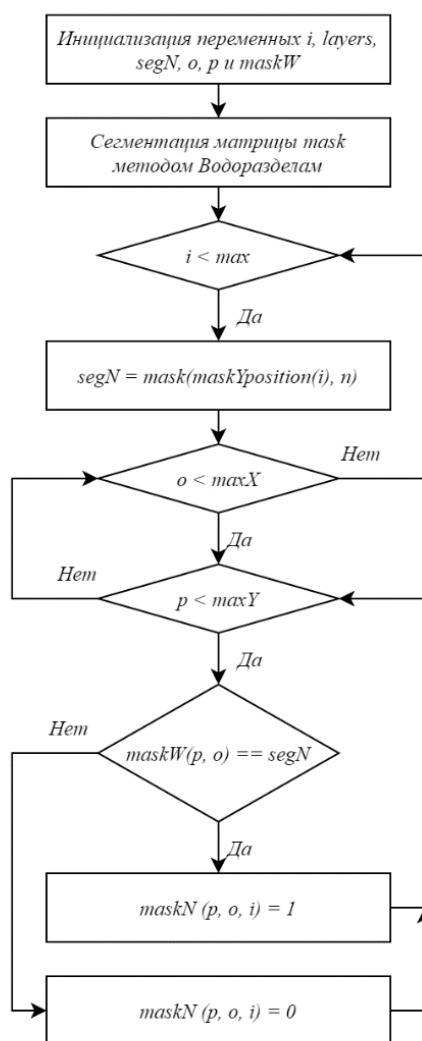


Рис. 3.4. Алгоритм разделение маски на слои




Рис. 3.5. Разделение сегментированной маски на слои

Последним и заключительным этапом является оцифровка ЭКГ-сигналов, которые были сегментированы и разделены на слои в предыдущих действиях, а также классификация R-пика. Изначально происходит умножение маски на исходное изображение ЭКГ, что позволяет избавиться от лишней информации и избежать оцифровки не исследуемого ЭКГ-сигнала. Далее необходимо пройтись по всем столбцам исходного изображения с поиском элемента, соответствующего цвету ЭКГ-сигнала, значение строчки которого будет записываться в созданную переменную, данные нормируются по отношению к «центральной» линии, а также подстраиваются к значениям исходных клеток миллиметровки, которые были найдены ранее.

Для классификации R-пика, демонстрирующийся на структурной схеме рис. 3.6, необходимо взять первую производную от получившего ЭКГ-сигнала. После выполнения данной итерации, результат которой представлен на рис. 3.7, резкие подъем и спад между Q-, R- и S-пиками отчетливо фиксируются и позволяют с большой вероятностью определить расположение R-пика, нежели на исходном сигнале.





Рис. 3.6. Структура ЭКГ



Рисю 3.7. Исходный ЭКГ-сигнал (сверху) и его первая производная (снизу)

Изначально происходит поиск S-пигов, которые имеют максимальные отрицательные значения. Для этого находится минимальное значения всей первой производной ЭКГ-сигнала при помощи встроенной функции *min* и элементам, чьи значения больше или равны «0,25» от вычисленного максимального отрицательного значения, присваивается значения «0». Данное граничное значение выбрано из соображений отсеивания незначительных всплесков, которые присутствуют на первой производной. Далее запускается цикл, который производит поиск минимального значения и, после его нахождения, записывает значения оси X и Y, удаляя при этом интервал в «5» условных единиц по оси X до и после

найденного значения. Данная итерация необходима для предотвращения повторной записи ранее найденных значений. В тот момент, когда минимальное значение будет равняться «0», алгоритм прекращает свою работу.

Поиск R-пиков производится в области 25 условных единиц строго с левой стороны от найденных значений S-пиков. Поскольку между Q- и R-пиками на исходном ЭКГ-сигнале наблюдается подъем, то на графики первой производной он будет значительно усилен, что позволяет производить поиск при помощи встроенной функции *max*. Алгоритм по структуре полностью повторяет поиск S-пиков.

Q-пики на графики первой производной являются точками перегиба после R-пиков, что упрощает их нахождение. Алгоритм вычисляет координаты и вносит их в итоговую таблицу, содержащую значения Q-, R- и S-пиков.

По итогу работы данного классификатора получается база данных, которая указывает на расположение R-пиков на исходном ЭКГ-сигнале, а также на QRS-интервал, которые отображают информацию о сокращениях предсердия и процессах возбуждения желудочков. Результаты оцифрованных ЭКГ-сигналов с демонстрацией работы классификатора R-пиков приведены на рис. 3.8. и 3.9.

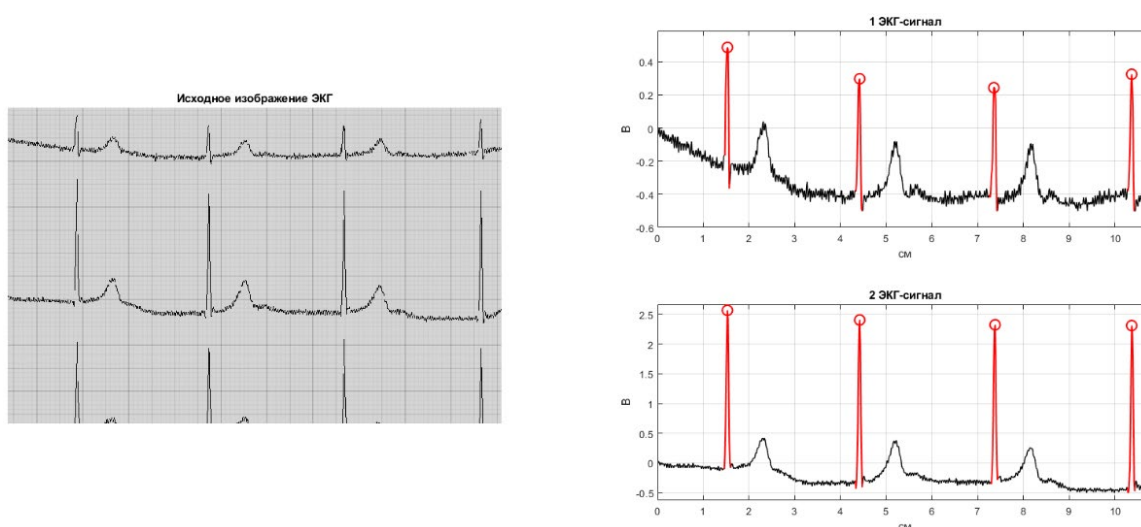


Рис. 3.8. Результат извлечение диагностической информации из изображения ЭКГ



Рис. 3.9. Результат извлечение диагностической информации из изображения ЭКГ

### 3.2. Выводы

В представленной главе было представлено описание алгоритма извлечения диагностической информации из изображений ЭКГ. Была реализована сегментация ЭКГ изображений с помощью U-Net, которая лежит в основе данного алгоритма. Для оценивания достоверности работы нейросетевой архитектуры были получены оценки коэффициента Dice, значения которых свидетельствуют о высокой точности предложенного метода решения поставленной задачи. При визуальной оценке результатов на рис. 3.9. можно сделать вывод об эффективности разработанного подхода, поскольку полученные данные повторяют форму аналоговой версии на изображении ЭКГ. Классификатор R-пигов демонстрирует приемлемые результаты, имея ошибку в 7%, что корректируется с дальнейшим усовершенствованием алгоритма.

## ЗАКЛЮЧЕНИЕ

В ходе работы был реализован алгоритм извлечения диагностической информации из изображения ЭКГ. От точности произведённой сегментации зависит корректность извлечённой диагностической информации и, как следствие, точность поставленного диагноза. В связи с этими особенностями был произведен обзор и анализ существующих на сегодняшний день методов сегментации, которые разделены на две основные группы: методы на основе глубокого обучения и классические алгоритмы. В связи с тем, что участие пользователя является неотъемлемой частью классических методов в случаях выделения объекта ограничивающим прямоугольником, ввода количества кластеров и других аспектов, данные алгоритмы оказались непригодны для поставленной задачи. Поэтому выбор для задач извлечения диагностической информации из изображений ЭКГ остановился на методах глубокого обучения, а именно на улучшенной полносвёрточной нейронной сети U-Net, состоящей из симметричных последовательных частей: энкодера и декодера. Она обладает высокой точностью работы при небольших временных затратах обучения, а также не требует внушительного количества изображений для обучения. На разработанном наборе данных была обучена выбранная модель для сегментирования ЭКГ-сигналов.

Был реализован алгоритм автоматической сегментации ЭКГ-сигналов, использующий результаты работы нейронной архитектуры, с дальнейшим извлечением диагностической информации. Алгоритм прошел тестирования на изображениях, которые имеют разное количество объектов интереса, а также области пересвета и затемнения. Значения коэффициента Dice в среднем составляют 92%, что позволяет сделать вывод о высокой производительности предложенного алгоритма.

В качестве дальнейшей работы по развитию разработанного алгоритма предлагается разработать расширенную версию классификатора, который

позволит в автоматическом режиме определять признаки ЭКГ-сигнала для постановки диагноза без участия медицинского работника.

Поставленные задачи были выполнены. Дальнейшая работа должна быть направлена на применение предложенных способов улучшения. Отдельные вопросы были обсуждены на «Конференции бакалавров Высшей школы теоретической механики» 2021 г.



## СПИСОК ЛИТЕРАТУРЫ

1. Гонсалес Р., Вудс Р. Цифровая обработка изображений. Москва: Техносфера, 2019. – 1104 с.
2. Джакония В. Е. Новые телевизионные системы высокого качества изображения // Телевидение. Москва: Горячая линия — Телеком, 2002. – 615 с.
3. Трасс Х. Х. Геоботаника. История и современные тенденции развития. Изд-во «Наука», 1976. — 252 с.
4. Уилкинсон Дж. Х. Алгебраическая проблема собственных значений. Изд-во «Наука», 1970. – 565 с.
5. Умбиталиев А. А., Цыцулин А. К. Теория и практика космического телевидения СПб.: НИИ телевидения, 2017. 368 с.
6. Цыцулин А. К., Адамов Д. Ю., Манцветов А. А., Зубакин И. А. Твердотельные телекамеры: накопление качества информации. – СПб., Изд-во СПбГЭТУ «ЛЭТИ», 2014. – 234 с.
7. Bhagyashri G. Patil, Sanjeev N. Jain Cancer Cells Detection Using Digital Image Processing Methods // International Journal of Latest Trends in Engineering and Technology (IJLTET), vol. 3, 2014.
8. Bolya D., Zhou C., Xiao F., Lee Y. YOLACT: Real-Time Instance Segmentation // 2019 IEEE/CVF International Conference on Computer Vision (ICCV), Seoul, Korea (South). 2019. P. 9156-9165.
9. Bote J. M., Recas J., Rincon F., Atienza D., Hermida R. A modular low-complexity ecg delineation algorithm for real-time embedded systems // IEEE J. Biomed. Health Inform. –2018. – P. 429–441
10. Canny J. A Computational Approach to Edge Detection // IEEE Transactions on Pattern Analysis and Machine Intelligence. –1986. – P. 679–698
11. Cardiovascular diseases (CVDs) // World Health Organization official site – 2017. – URL: [https://www.who.int/en/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/en/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)) – (дата обращения: 21.04.2021).

12. Glorot X., Bordes A., Bengio Y. Deep sparse rectifier neural networks // Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, PMLR 15:315-323, 2011.
13. K-means clustering. [Электронный ресурс]. URL: <http://www.onmyphd.com/?p=k-means.clustering> (Дата обращения: 21.04.2020).
14. Kornilov A.S., Safonov I.V. An Overview of Watershed Algorithm Implementations in Open Source Libraries // J. Imaging, 2018.
15. Lin T. Y., Maire M., Belongie S., Hays J., Perona P., Ramanan D., Dollar P., Zitnick L. Microsoft coco: Common objects in context // ECCV, 2014.
16. Long J., Shelhamer E., Darrell T. Fully convolutional networks for semantic segmentation // Proceedings of the IEEE conference on computer vision and pattern recognition. –2015. – P. 3431-3440.
17. MathWorks [Электронный ресурс]. Режим доступа: <https://www.mathworks.com/> (дата обращения 21.04.2021).
18. Muthukrishnan .R, Radha M. Edge detection techniques for image segmentation // International Journal of Computer Science & Information Technology (IJCSIT) Vol 3, No 6, Dec 2011.
19. Pettis K.S., Savona M.R., Leibrandt P.N., Maynard C., Lawson W.T., Gates K.B., Wagner G.S. Evaluation of the efficacy of hand-held computer screens for cardiologists' interpretations of 12-lead electrocardiograms // Am Heart J. 138 (4 Pt 1): 765-70, 1999
20. Ronneberger O., Fischer P., Brox T. U-net: Convolutional networks for biomedical image segmentation // International Conference on Medical image computing and computer-assisted intervention. – Springer, Cham, 2015. – P. 234-241.
21. Salerno S.M., Alguire P.C., Waxman H.S. Training and competency evaluation for interpretation of 12-lead electrocardiograms: recommendations from the American College of Physicians // American College of Physicians. Ann Intern Med 138(9): 747-50, 2003 May 6
22. Sezgin M., Sankur B. Survey over image thresholding techniques and quantitative performance evaluation // J. Electronic Imaging 13 (1): 146-168, 2004.